

プライベートRAG構築のあらまし

自己紹介

- ・ 名前: 濱田
 - ・ 職業: 某発電所のメンテナンス関係に従事
※ITは本職ではありません。
-

用語説明

RAG

検索拡張生成。外部のデータソースから関連する情報を検索し、LLMに提示して回答を生成する技術。

LLM

大規模言語モデル。膨大なテキストデータから学習し、人間のような自然な文章の理解や生成を行うAIモデル。

Embedding

テキストの意味を多次元ベクトル空間に変換する技術。

Chunk

文書进行处理可能な適切なサイズに分割した断片。

Vector

数値のリストとして表現されたデータの数学的表現。

システム構成：ハードウェア

embedding／推論CPU	Intel Core i7-1165G7 (4C/8T, 2.8GHz)
embedding／推論メモリ	64GB
embedding／推論GPU	NVIDIA RTX2060
データベースCPU	Core i5 8200Y 1.3GHz
データベースメモリ	8GB

システム構成：ソフトウェア

項目	詳細バージョン / ライブラリ
python環境	Anaconda (Python 3.10.2)
主要ライブラリ	transformers (5.5.4)
	llama-cpp-python (0.3.20)
データベース	PostgreSQL 18

手順

データ取得

Webからテキスト情報を取得。



chunking

長い文章を適切な長さに分割する処理。



embedding

分割したテキストを数値の羅列(ベクトル)に変換する処理。

DB格納

データベースに格納。



推論

格納されたデータをLLMと連携し、検索拡張生成を実現。

Embedding

Embedding（エンベディング：埋め込み表現）とは、単語や文章の意味をコンピューターが理解しやすい「数値の羅列（ベクトル）」に変換することで、言葉の意味的な近さや文脈を計算できるようになります。

モデルの整合性

- ・ 推論に使用するモデルとEmbeddingのモデルを合わせることは重要。

次元の罠

- ・ 闇雲に次元数を増やしても、必ずしも検索の精度が上がるわけではない。増大するコストのほう
がデメリットが大きくなる

Chunking

Chunking（チャンキング）とは、長い文章をLLMやEmbeddingモデルが適切に処理できるよう、意味のある適度な長さの断片（チャンク）に分割するプロセスのことです。

不用意なチャンク化の問題点 ①

- ・ 同じチャンクがDB内に存在する場合、推論で同じ内容を繰り返す。

不用意なチャンク化の問題点 ②

- ・ 意味的にチャンクが分割されてしまうと適切な回答ができない

今後の課題

モデルの変更

推論モデル: Qwen2.5-7B-Instruct-q4_K_M.gguf

embeddingモデル: BAAI/bge-m3

推論に使用している llama-cpp-pythonがGPUに対応していないので動作が遅くて不満

データクレンジングが必要

システムの精度向上のため、適切なデータクレンジング手法が必要。

質疑応答

Q&A Session
